

# به نام خدا

پاسخ بخش تئوری تمرین اول درس پردازش زبان طبیعی

استاد درس: دکتر یاسمن برشبان

علی افشار دگرسی ۱۴۰۴۱۲۲۶۱۵۱۰۱

سوال اول: معیار ارزیابی

برای یک دسته بندی دو کلاس نتایج زیر به دست آمده است.

الف (TP, FN, FP, TN) را مشخص کنید.

پاسخ:

$$TN = 30, TP = 45, FN = 15, FP = 10$$

ب) معیارهای accuracy, F1, recall, precision را محاسبه کنید.

پاسخ:

$$Accuracy = \frac{TP + TN}{TP + TN + FP + FN} = \frac{75}{100}$$

$$Precision = \frac{TP}{TP + FP} = \frac{45}{55}$$

$$Recall = \frac{TP}{TP + FN} = \frac{45}{60}$$

$$F1 = \frac{2}{\frac{1}{Precision} + \frac{1}{Recall}} = \frac{2}{\frac{55}{45} + \frac{60}{45}} = \frac{2}{\frac{115}{45}} = \frac{90}{115}$$

## سوال دوم: نایوبیز

با توجه به جدول زیر مشخص کنید سند شماره 6 مربوط به چه کلاسی است. از روش نایوبیز با استفاده از هموارسازی add-1 استفاده کنید.

Documents	Words	Class
1	Technology, Stemming, Lemmatization, Learning	AI
2	Recognition, Learning, Data	AI
3	Neural, Network, Lemmatization	AI
4	Router, Switch, Network	Network
5	Network, Bandwidth, Router	Network
6	Recognition, Learning, Router	?

پاسخ:

$$\hat{P}(w|c) = \frac{\text{count}(w, c) + 1}{\text{count}(c) + |V|} \quad |V| = 11$$

$$P(AI) = \frac{3}{5} \quad P(Network) = \frac{2}{5}$$

$$\text{count}(AI) = 10 \quad \text{count}(Network) = 6$$

$$\hat{P}(Recognition|AI) = \frac{1+1}{10+11} = \frac{2}{21} \quad \hat{P}(Learning|AI) = \frac{2+1}{10+11} = \frac{3}{21}$$

$$\hat{P}(Router|AI) = \frac{0+1}{10+11} = \frac{1}{21} \quad P(AI|d6) \propto \frac{3}{5} * \frac{2}{21} * \frac{3}{21} * \frac{1}{21} \simeq 0.0004$$

$$\hat{P}(Recognition|Network) = \frac{0+1}{6+11} = \frac{1}{17} \quad \hat{P}(Learning|AI) = \frac{0+1}{6+11} = \frac{1}{17}$$

$$\hat{P}(Router|AI) = \frac{2+1}{6+11} = \frac{3}{17} \quad P(Network|d6) \propto \frac{2}{5} * \left(\frac{1}{21}\right)^2 * \frac{3}{21} \simeq 0.0001$$

**$P(AI|d6) > P(Network|d6) \Rightarrow \text{so answer is AI}$**

سوال سوم: پیش پردازش + نایویز

ج) مقایسه داده خام و داده پیش پردازش شده  
با توجه به نتایج به دست آمده از مرحله قبل به سوالات زیر پاسخ دهید.

1. کدام مراحل پیش پردازش بیشترین تاثیر را بر بهبود مدل داشته‌اند؟  
پاسخ: مرحله فقط نرمال سازی بدون کارهای دیگر، بیشترین بهبود را داشته است.

2. آیا حذف stopwords باعث کاهش یا افزایش دقت شده؟ چرا؟  
پاسخ: کاهش، به این علت که بعضی از توکن‌هایی که به عنوان stop word حذف شده‌اند در تفاوت معنای جملات تاثیر داشته و باعث تمایز بهتر می شدند.

3. پیش پردازش چگونه روی کلاس‌های مختلف (مثبت/منفی/خنثی) تاثیر گذاشته؟  
پاسخ: بیشترین تاثیر را روی کلاس‌های مثبت و منفی داشته و کمترین تاثیر را روی کلاس خنثی داشته است. نرمال سازی باعث بهبود و lemmatization و حذف stop word نیز باعث افت عملکرد شده‌اند.

سوال چهارم: پیاده سازی سیستم بازیابی اطلاعات (IR) فارسی با TF-IDF بر روی PQuAD

(د) مقایسه عملکرد با و بدون پیش پردازش

تمام مراحل بخش ب و ج را یک بار دیگر انجام دهید، اما این بار بدون هیچ پیش پردازشی. نتایج دو حالت را مقایسه کنید:

- دقت و MRR چقدر تغییر کرده اند؟

- کدام مقادیر بهبود یافته یا بدتر شده اند؟

پاسخ:  $\text{precision@5}$  و  $\text{recall@5}$  بدتر شده اند ولی MRR بهبود یافته است.

- چرا پیش پردازش در برخی پرسش ها اثر بیشتری گذاشته است؟

پاسخ: با حذف stopword ها یا علامت های نگارشی، سائز vocab کمتر شده و فضای مسئله

ما دارای ابعاد کمتری نسبت به حالت عادی می باشد، پس هم معیار فاصله ما بهتر متمایز می کند هم توجه به توکن هایی که خاص تر می باشند بیشتر می شود. از طرفی ممکن است توکن هایی که در واقع اهمیت بیشتری دارند به اشتباه حذف شوند.

(ه) تحلیل خطا و ارائه پیشنهادهای بهبود

برای 3 تا 5 سوال که سیستم در آنها عملکرد ضعیفی داشته (مثلاً سند درست در رتبه های پایین قرار گرفته)

1. متن سؤال را نشان دهید.

2. سند درست را نمایش دهید.

3. سه سند اول رتبه بندی شده را مقایسه کنید.

4. توضیح دهید چرا IDF-TF اشتباه کرده است .
5. حداقل سه راهکار برای بهبود سیستم پیشنهاد کنید .

پاسخ:

سوال اول: "زندر چیست؟"

سند درست:

"بالا بردن میزان نرخ زمانی کلاک و که سبب تولید هشریت (میزان محاسبه اطلاعات توسط پردازنده در واحد زمان است)، بیشتر در واحد زمان و انجام سریع تری محاسبه در بازه زمانی می شود. پردازنده هایی که قفلشان بازگشایی شده باشد را می توان اورکلاک کرد و مزیت اورکلاک، انجام سریع تر پردازش و رندرهای سنگین توسط پردازنده است. مضرات اورکلاک بالا رفتن دمای پردازنده برای محاسبه و در نتیجه استفاده مداوم سبب پایین آمدن عمر پردازش گر می شود. عمل Overclocking نیازمند دانش کافی در زمینه سخت افزار می باشد و هرگونه اقدام نادرست، آسیب های جبران ناپذیری به پردازنده ها وارد می کند. تنها پردازنده هایی اورکلاک می شوند که قابلیت اورکلاک شدن را در پسوند خود داشته باشند...."

سند اول بازیابی شده:

"در سه سالگی، او شروع به شرکت در آموزش های رقص در زادگاهش، کنتوود، لوئیزیانا کرد و برای اجرا به عنوان یک هنرمند انفرادی در مراسم سالانه موسیقی انتخاب شد. اسپیرز در سن پنج سالگی، اولین حضور خود را در صحنه محلی با اجرای آواز «این کودک چیست؟» در کودکانستان فارغ التحصیلی خود آغاز کرد. او همچنین در دوران کودکی خود درس های ژیمناستیک و آواز را آموخته بود و در بسیاری از مسابقات در سطح ایالت و نمایش های استعدادیابی کودکان پیروز شد. او درباره اهداف خود در دوران کودکی گفت، «در دنیای خودم بودم، [...] من در سنین پایین متوجه شدم که قرار است چه کاری انجام دهم»"

سند دوم بازیابی شده:

"نخستین استفاده از واژه جنگ سرد برای اشاره به رقابت ژئوپلیتیکی پساجنگ بین ایالات متحده آمریکا و اتحاد جماهیر شوروی در سخنرانی برنارد باروک از مشاوران مهم رئیس جمهوران دموکراتیک آمریکا و در ۱۶ آوریل ۱۹۴۶ آمده است. در این سخنرانی که توسط روزنامه‌نگار هربرت بایارد اسووپ [واژه‌نامه 3] نوشته شده است چنین آمد: «نباید فریب بخوریم، ما امروز در میانه یک جنگ سرد به سر می‌بریم». والتر لپمن روزنامه‌نگار با گلباش جنگ سرد به این اصطلاح رواج بیشتری داد. در ۱۹۴۷ وقتی از لپمن پرسیده شد خاستگاه این اصطلاح چیست وی گفت که برگرفته از یک اصطلاح فرانسوی دهه ۱۹۳۰ است: la guerre "froide"

سند سوم بازیابی شده:

"به تعریفی دیگر تاریخ، دانش واکاوی پیشامدهای گذشته است، علمی که بشر بر مبنای آن این امکان را می‌یابد که بگوید حوادث تاریخی در یک سلسله زمانی رخ داده‌اند. بحث تعریف تاریخ و علم تاریخ در نزد گذشتگان و معاصران ابداعی نیست و در نگاه اجمالی به مفهوم زمان تأکید ویژه‌ای دارد. هر تعریفی که ارائه می‌شود بر منظری است که از آن زاویه مطرح می‌شود. مفهوم تاریخ نیز از مفاهیمی مانند گذشته، طبیعت و هستی متفاوت است. تاریخ مربوط به گذشته است ولی فایده تاریخ برای گذشته نیست بلکه برای زمان حال و آینده تأثیر بسیاری دارد. تاریخ بازسازی گذشته بر اساس مدارک و اسناد است و اینکه مدرک و سند چیست و چه چیزی را سند و مدرک تلقی کنیم بحث مهمی در علم تاریخ به شمار می‌آید. نظریه‌ای که یک مورخ دارد بایستی به تأیید مورخان برسد و مورخان دیگر نیز با آن نظریه موافقت کنند، اگر مورخان بر نظریه‌ای که مبتنی بر واقعیت‌هایی که از اسناد و مدارک ذکر می‌شود، توافق کنند آن نظریه باعث می‌شود حقایق به واقعیت‌های تاریخی بدل شوند."

علت اشتباه: به این علت که ما lemmatization یا stemming انجام نداده ایم، توکن "رندر" با اینکه در دیتاست نادر است و idf بالایی دارد ولی با توکن "رندرهای" متفاوت در نظر گرفته شده و معیار مقایسه بیشتر روی توکن "چیست" تمرکز کرده و سند هایی که دارای این توکن هستند را در ابتدا می آورد.

راهکارها:

1. با استفاده از lemmatization یا stemming میتوانیم توکن "رندرهای" و "رندر" را به یک ریشه مشترک تبدیل کنیم تا یک توکن در نظر گرفته شوند.
2. وقتی توکن "رندر" را می بینیم میتوانیم با گسترش متن سوال و اضافه کردن مترادف های آن مثل "پردازش" یا ... نتیجه را بهبود دهیم.
3. حتی می توانیم در هنگامی که vocab خود را میسازیم و توکن ها را استخراج میکنیم، علاوه بر ریشه یابی، تحلیل معنایی نیز بکنیم و از لحاظ معنایی به یک توکن واحد مرتبطشان کنیم. که هم سباز vocab را ممکن است کمتر کند هم ارتباط را بهتر در نظر بگیرد

سوال دوم: "الگوریتم به چه معناست؟"

سند درست:

"کارایی پردازش کامپیوترها، با استفاده از پردازنده های چند هسته ای که اساساً اتصال دویا بیش از دو پردازنده ی مجزا (با نام هسته ها، در این زمینه) در یک مدار مجتمع است، افزایش می یابد. به طور ایده آل، یک پردازنده ی دو هسته ای تقریباً قدرت معادل دو برابر یک پردازنده تک هسته ای دارد، اما در واقعیت، افزایش کارایی بسیار کمتر از این است و حدود تقریباً ۵۰٪ است که دلیل آن، الگوریتم های نرم افزاری و پیاده سازی های ناکامل است. افزایش تعداد هسته ها در یک پردازنده (یعنی دو هسته ای، چهار هسته ای و ...)

موجب افزایش میزان بار کاری قابل انجام توسط پردازنده می شود. این بدان معنی است که این پردازنده ها می توانند وقایع ناهمگام، وقفه ها و ... را که در حجم زیاد می توانند اثرات مخربی روی عملکرد پردازنده داشته باشند، مدیریت کنند. این هسته ها را می توان به شکل طبقات مختلف در یک ساختمان پردازش در نظر گرفت که هر طبقه یک وظیفه ی متفاوت را انجام میدهد. گاهی این هسته ها، در زمانی که یک هسته به تنهایی برای مدیریت اطلاعات کافی نباشد، می توانند کاری مشابه با هسته های مجاور خود انجام دهند."

سند اول بازیابی شده:

"مناطق جغرافیایی خاص می توانند مورد مطالعه تاریخی قرار گیرند، برای نمونه، قاره ها، کشورها و شهرها. درک این که چرا مکان وقایع تاریخی صورت گرفته مهم است، برای انجام این کار، مورخان اغلب به جغرافیا روی می آورند. الگوهای آب و هوایی، منابع آب موجود و چشم انداز از مکان زندگی، همه، بر روی مردمی که در آنجا زندگی می کنند، اثر می گذارد. برای نمونه، برای توضیح اینکه چرا مصریان باستان تمدنی موفق را گسترش دادند، مطالعه جغرافیای مصر ضروری است. تمدن مصری در ساحل رود نیل ساخته شده بود که طغیان های سالانه نیل، خاک حاصل خیزی را به ساحل می آورد. خاک غنی می تواند به کشاورزان کمک کند تا محصولات کافی را رشد دهند و به تأمین خوراک مردم شهر پردازند. این بدان معناست که هرکس مزرعه کشاورزی نداشت، بنابراین دیگر مردم می توانستند کارهای دیگری انجام دهند که به رشد و توسعه تمدن کمک می کرد."

سند دوم بازیابی شده:

"باستان شناسی رشته ای علمی است که به طور ویژه به بررسی و کاوش محوطه های باستانی و اشیاء قدیمی که کشف شده اند می پردازد و به مطالعه تاریخ کمک می کند. اما باستان شناسی به ندرت می تواند به تنهایی مورد استفاده قرار گیرد، به این معنا که در این دانش، از منابع روایی و مکتوب تاریخی برای تکمیل آنچه کشف شده است استفاده می شود. البته، باستان شناسی



متشکل از بازه گوناگونی از روش‌شناسی‌ها و رویکردهاست که هر کدام آن‌ها مستقل از تاریخند؛ این بدان معناست که باستان‌شناسی خلأها و شکاف‌های ناشی از منابع مکتوب را پر نمی‌کند. در واقع، باستان‌شناسی تاریخی شاخه‌ای ویژه از باستان‌شناسی است که بیشتر، نتیجه‌گیری‌های آن با آنچه منابع متنی می‌گویند، متضاد است." سند سوم بازیابی شده:

"سال ۱۳۴۹ کانون پرورش فکری کودکان و نوجوانان سبب شد تا بیضایی دو کار نکرده را نخستین بار بیازماید: داستان نوشتن برای کودکان و فیلم‌سازی. حقیقت و مرد دانا را به خواهرش فیروز شیروانلو نوشت؛ و این نخستین و واپسین آزمونش در این کار بود؛ ولی فیلم‌سازی همان بویه‌ای بود که از نوجوانی درپیش بود و یک بار هم به‌طوری محدود با یک دوربین ساده دست داده بود، ولی این بار می‌توانست فیلمی برای نمایش روی پرده بزرگ بسازد. حاصل کار عمو سیبیلو شد، که راهی بود برای آن که بیضایی سرانجام بتواند کار سینمایی کند. فیلم‌سازی جدی‌ترش از دهه ۱۳۵۰ مقدور شد، ولی همچنان نشد که فیلمنامه بزرگی چون عیار تنها را فیلم کند."

علت اشتباه: مثل سوال قبل ولی اینبار برای توکن‌های "الگوریتم" و "الگوریتم‌های"

راهکارها: مثل سوال قبل

سوال سوم: "ناصرالدین‌شاه چه اقدامات مهمی را در زمان پادشاهی خود انجام داد؟" سند درست:

"در آستانه مراسم پنجاهمین سال تاجگذاری در سال ۱۲۷۵ هجری خورشیدی (۱۷ ذی‌القعدة ۱۳۱۳ هجری قمری) به دست میرزا رضای کرمانی یکی از پیروان سید جمال‌الدین اسدآبادی و به تحریک او در حرم شاه عبدالعظیم در شهر ری ترور شد. او در هنگام ترور

پنجاهمین سالگرد سلطنت خویش را جشن می گرفت. وی در زیارتگاه شاه عبدالعظیم در شهر ری در نزدیکی تهران دفن است. سنگ قبر یک پارچه مرمری وی که تمثال کامل وی بر آن حکاکی شده هم اکنون در موزه کاخ گلستان در تهران نگهداری می شود و به یکی از شاهکارهای کنده کاری دوره قاجار معروف است."

سند اول بازیابی شده:

"ناصرالدین شاه (۲۵ تیر ۱۲۱۰ - ۱۲ اردیبهشت ۱۲۷۵) که پیش از دوران پادشاهی ناصرالدین میرزا خوانده می شد، معروف به «قبله عالم»، «سلطان صاحبقران» و بعد از کشته شدن توسط میرزا رضای کرمانی «شاه شهید»، چهارمین شاه از دودمان قاجار ایران بود. او با نزدیک به ۵۰ سال پادشاهی، پس از شاپور دوم ساسانی و تهماسب اول صفوی طولانی ترین دوره پادشاهی در میان تمامی شاه های تاریخ ایران را داراست. او به افتخار نیم قرن سلطنت بر ایران، خود را صاحبقران نامید. او همچنین نخستین پادشاه ایران بود که خاطرات خود را نوشت. همچنین، ناصرالدین شاه اولین پادشاه ایرانی بود که در رأس هیئت حاکمه برای بازدید از تمدن و تکنولوژی غرب عازم اروپای نوین شد. او اولین صدراعظم خود، امیرکبیر را کشت و سید محمدعلی، مؤسس آئین بابی را نیز توسط امیرکبیر اعدام کرد. ناصرالدین شاه در سال ۱۲۷۵ خورشیدی و در آستانه مراسم پنجاهمین سال پادشاهی اش به ضرب گلوله در سن ۶۵ سالگی ترور شد. او را در حرم عبدالعظیم حسنی در شهر ری در جنوب شهر تهران به خاک سپردند."

سند دوم بازیابی شده:

"تأسیس مدرسه های خارجی در ایران از زمان محمدشاه و با فعالیت گروه های میسیونر آغاز شده بود. در اواخر دوره ناصرالدین شاه مدرسه های خارجی گسترش بیشتری در ایران یافتند. ناصرالدین شاه که در نخستین سفر اروپا با آدولف کرمیو رئیس اتحاد جهانی آلیانس ملاقات کرده بود، به او قول داد که اجازه فعالیت این مؤسسه در ایران و تأسیس مدارس را بدهد. در سال ۱۳۰۶ قمری دو شعبه از مدرسه آلیانس در تهران و شیراز تأسیس شد. ناصرالدین شاه

پس از چند سال به سبب شایعاتی که پیرامون فعالیت‌های ضدسلطنتی و ضد مذهبی این مدرسه به وجود آمده بود، مجوز فعالیت آلیانس را لغو کرد. برای جلب اعتماد شاه، مدیر مدرسه، ریاست عالی مدرسه را به شاه اهداء کرد و شاه بازگشایی دوباره آلیانس را پذیرفت. شمار مدارس میسیونری آمریکایی در دوران ناصرالدین شاه افزایش یافت و در تهران و سایر شهرهای ایران مدارس بیشتری تأسیس شد به طوری که در سال ۱۲۷۴ خورشیدی، تنها ۱۱۷ مدرسه در شمال غربی ایران (آذربایجان) فعالیت می کردند.

سند سوم بازیابی شده:

"در شهریور ۱۳۲۰، ایران به دست نیروهای دو کشور انگلستان و شوروی (و بعدها ایالات متحده) به بهانه همراهی رضاشاه با قوای آلمان مورد هجوم گسترده قرار گرفت که از تاب تحمل ارتش نوپای ایران خارج بود و رضاشاه پهلوی پیش از رسیدن قوای متفقین به تهران از پادشاهی استعفا داد و فرزندش را به عنوان جایگزین به مجلس شورای ملی معرفی کرد که مورد تصویب قرار گرفت. این اقدامات به پیشنهاد محمد علی فروغی صورت گرفت تا راه سوء استفاده متفقین را ببندد. بدین ترتیب سالهای آغازین پادشاهی وی با اشغال ایران و پایان جنگ دوم جهانی مصادف شد. [نیازمند منبع]"

علت اشتباه: اینطور به نظر میرسد که سند درست ارتباط زیادی به سوال ندارد، و اشتباه از ارتباط گذاری اولیه است و مدل به درستی کار کرده است.

راهکارها: -